

apresentação

238719

2025-10-23

# Agenda

## Roteiro da Apresentação:

1. **Introdução** - Contexto e objetivos
2. **Metodologia** - Como foi a simulação
3. **Resultados** - Gráficos e análises
4. **Conclusões** - Principais achados
5. **Estimação de Variância** - Revolução computacional
6. **Amostras Não-Probabilísticas** - Novo paradigma
7. **Tendências Futuras** - Horizontes emergentes
8. **Recomendações** - Aplicações práticas

# Introdução – Amostragem em Crise e a Necessidade de Adaptação

**Contexto:** A amostragem em pesquisas (Survey Sampling) passou por uma transformação radical nas últimas cinco décadas (1973-2023).

**O Problema Central:** A principal força motriz dessa mudança é o declínio dramático nas taxas de resposta, que compromete a validade e a precisão das estimativas baseadas em métodos tradicionais.

**Objetivo do Artigo** (de Waal & Scholtus, 2023): Mapear as inovações estatísticas criadas para preservar a qualidade da pesquisa em um cenário de coleta cada vez mais desafiador.

# Problema de Pesquisa: A Resposta Estatística à Não-Resposta

**Nossa Pergunta:** Como as novas metodologias de amostragem, especialmente o Model-Assisted Sampling, conseguiram mitigar o viés e manter a precisão das estimativas diante do declínio das taxas de resposta?

## **Metodologias em Foco:**

- Estimadores Auxiliados por Modelo (GREG): Uso de dados auxiliares para correção de viés.
- Métodos de Replicação (Bootstrap): A revolução computacional na estimação de variância.
- Amostras Não-Probabilísticas: Tendências e desafios futuros.
- Objetivo do Nosso Trabalho: Simular e comparar o desempenho do estimador GREG contra métodos tradicionais ao longo de 50 anos de crise na taxa de resposta.

# Metodologia - O Cenário da Simulação de 50 anos (1973 - 2023)

## 1. População Simulada:

- ▶ **50 anos** analisados
- ▶ **5.000 indivíduos** por ano

## 2. Variáveis de estudo: $X$ (auxiliar) e $Y$ (interesse)

- ▶ **Relação Modelada:**  $Y$  foi gerada em função de  $X$  (ex.:  $Y \approx \beta_0 + \beta_1 X + \epsilon$ ), imitando uma regressão que justifica o uso do GREG.

## 3. Processo de Não-Resposta:

**Declínio da Resposta:** A Taxa de Resposta decaiu de  $\approx 70\%$  (1973) para  $\approx 25\%$  (2023), conforme o cenário do artigo.

**Viés de Seleção:** A não-resposta foi simulada como Não-Resposta com Viés (Non-Response with Bias). A probabilidade de um indivíduo responder ( $\phi_k$ ) foi definida para ser correlacionada com a variável de interesse  $Y$ .

# Metodologia – Os Estimadores em Comparação: Tradicional vs. Model-Assisted

## 1. Estimador Tradicional (Média Simples - Horvitz-Thompson):

**Princípio:** Estima o total populacional usando apenas os dados da amostra respondente e o peso amostral inicial.

**Fragilidade:** É altamente vulnerável ao viés da não-resposta. Se os respondentes não forem uma subamostra aleatória dos amostrados, a estimativa se torna enviesada.


## 2. Estimador Assistido por Modelo (GREG - Generalized Regression Estimator):

**Princípio:** Utiliza a **Variável Auxiliar ( $X$ )** conhecida em  $\mathcal{U}$  para modelar a relação com  $Y$  e, então, ajustar o peso dos respondentes. **Fórmula**

**(Conceito):**  $\hat{Y}_{GREG} = \sum_{k \in \mathcal{U}} \hat{Y}_k + \sum_{k \in \mathcal{R}} w_k (Y_k - \hat{Y}_k)$  Ele calibra os pesos dos respondentes para que a sua distribuição de  $X$  se ajuste à distribuição populacional de  $X$ . **Força:** Reduz drasticamente o viés da não-resposta, assumindo que o viés é explicado pela variável auxiliar  $X$ . **Métrica de Avaliação:** O

# Evolução da Taxa de Resposta


Queda Acelerada nas Taxas de Resposta



**Resultado: \* 72% em 1973 → 28.3% em 2023**  
**Redução de 60.7% em 50 anos**

# Impacto na Qualidade das Estimativas

## Comparacao do Vies: Metodo Tradicional vs GREG




**Conclusão: GREG mostra viés consistentemente menor que o método tradicional**



# Métodos de Estimação ao Longo do Tempo

## Evolução das Estimativas por Metodo



**Observação: GREG segue mais de perto o valor real ao longo de todo o período**

# Análise por Década: A Superioridade Crescente do GREG

Table 1: Tabela 1: Desempenho dos Estimadores por Década

| Década | Taxa de Resposta Média | Viés Médio Absoluto (VMA) |
|--------|------------------------|---------------------------|
| 1970   | 67%                    |                           |
| 1980   | 62%                    |                           |
| 1990   | 53%                    |                           |
| 2000   | 43%                    |                           |
| 2010   | 33%                    |                           |
| 2020   | 27%                    |                           |

# Principais Conclusões

1. **Crise de Resposta** Taxas caíram dramaticamente, exigindo métodos mais robustos
2. **Superioridade do GREG** Redução média de 77.5% no viés vs método tradicional
3. **Adaptação Necessária** Métodos tradicionais tornam-se **inadequados** com baixa resposta
4. **Dados Auxiliares Cruciais** GREG aproveita **informações adicionais** para melhor precisão

# Estimação de Variância: Revolução Computacional

## A Necessidade da Mudança:

Com o desenvolvimento de **estimadores complexos** (como o GREG) e o uso de **desenhos amostrais sofisticados** (estratificação, múltiplos estágios), as fórmulas matemáticas para calcular a variância (erro) tornaram-se **intratáveis** ou impossíveis de derivar.

O avanço do **poder computacional** na virada do milênio foi a solução.

### ► **Evolução Histórica dos Métodos de Replicação:**

**1970s:** Fórmulas analíticas (Precisas, mas limitadas a **desenhos simples**.)

**1990s:** Jackknife e Balanced Half-Samples (Primeiros métodos de replicação usados em **surveys complexos**.)

**2000s+:** **Bootstrap e Replicação** (Tornou-se o **padrão**, capaz de estimar a variância para qualquer estatística (média, quartil, regressão).)

### ► **Vantagens dos Métodos Modernos (A Democratização da Variância):**

# Amostras Não-Probabilísticas: O Novo Paradigma de Velocidade vs. Viés

## ► **Cenário Atual: A Explosão da Não-Probabilidade**

**Impulsionadores:** Pressão por **custos menores**, demanda por **velocidade** na coleta e o surgimento de novas **fontes de dados** (painéis online, dados de mídia social, etc.).

**Definição:** A probabilidade de seleção de um indivíduo é **desconhecida**, dependendo da autoseleção ou da disponibilidade do pesquisador.

## ► **O Principal Desafio: Viés de Seleção**

**Problema:** A amostra não-probabilística é inerentemente **não-representativa**. As pessoas que se autoselecionam (ex: para um painel online) são estatisticamente diferentes da população.

**Consequência:** Resultados altamente sujeitos a viés de seleção desconhecido, comprometendo a inferência estatística.

## ► **Soluções Emergentes: A Estatística ao Resgate**

Para que essas amostras sejam úteis, é obrigatório aplicar ajustes para mitigar o viés:

# Tendências Futuras: A Amostragem na Era da Integração de Dados

- ▶ **O Futuro Imediato:** A amostragem evolui para ser menos dependente de um único survey e mais focada na **combinação inteligente** de múltiplas fontes.

- ▶ **1. Integração de Múltiplas Fontes de Dados (Hybrid Data):**

O paradigma muda de “coleta pura” para “integração”.

**Objetivo:** Combinar a **qualidade inferencial** das amostras probabilísticas (caras) com o **volume/velocidade** das amostras não-probabilísticas e dados administrativos (Big Data).

**Desafio Estatístico:** Desenvolver modelos que equilibrem o **viés** (de fontes não-probabilísticas) e a **variância** (de pequenas amostras probabilísticas).

- ▶ **2. Designs Adaptativos e Personalização (Adaptive Survey Designs):**

**Conceito:** A estratégia de coleta de dados se ajusta em **tempo real** (e.g., mudando de modo telefônico para online)

# Recomendações Práticas: O Caminho a Seguir na Amostragem

- ▶ **1. Para Pesquisadores e Estatísticos de Survey**
- ▶ **Adotar o Paradigma Model-Assisted:**  
**Tornar o GREG (Estimador de Regressão Generalizada) o padrão:** Utilizar estimadores assistidos por modelo para corrigir o viés da não-resposta e da não-cobertura.  
**Coletar Variáveis Auxiliares (X):** Priorizar a obtenção de variáveis externas e correlacionadas com a variável de interesse (Y) para maximizar a eficácia do GREG.
- ▶ **Utilizar Métodos de Replicação:**  
Implementar rotineiramente métodos como **Bootstrap** e **Jackknife** para estimar a variância, especialmente em desenhos complexos.  
**Vantagem:** Evita erros de derivação e simplifica a implementação em software.
- ▶ **2. Para a Agenda de Pesquisa Futura**
- ▶ **Abraçar a Integração Híbrida:**  
Focar no desenvolvimento de frameworks robustos para

# Resumo Executivo

## Problema:

O **Declínio acentuado na Taxa de Resposta** (queda de 60.7% em 50 anos) tornou os métodos tradicionais (Média Simples) **inadequados**, gerando um viés crescente nas estimativas.

## Solução:

A resposta estatística reside na **Amostragem Assistida por Modelo**. O **GREG** utiliza **dados auxiliares** ( $X$ ) para ajustar os pesos e corrigir o viés da não-resposta.

## Resultado:

O GREG demonstrou uma Superioridade Incontestável, alcançando uma redução média de **77.5% de redução no viés** comparado a métodos tradicionais

## Tendência

A amostragem exige **Integração de Dados** e o uso de métodos computacionais (Bootstrap, ML) para garantir a precisão em um ambiente de coletas cada vez mais complexas. —



# Obrigado!

**Trabalho acadêmico**

**Disciplina: Técnicas de Amostragem**

**Baseado em:**

**“Survey sampling during the last 50 years”**

*(de Waal & Scholtus, 2023)*